

Izmir Yuksek Teknoloji Enstitusu

Muhendislik Fakultesi
Bilgisayar Muhendisligi

TEZ / PROJE ONERISI

Yapay Zeka Destekli Aging-Aware Adaptive Time Quantum Scheduling

Cross-Layer Reliability Feedback ile Guvenilir ve Verimli Scheduler Tasarimi

Ogrenci Adi Soyadi:	[Ad Soyad]
Ogrenci Adi Soyadi:	Omer Faruk Teker
Ogrenci Numarasi:	Belirtilecek
Danisman:	Belirtilecek
Program:	Lisans
Ana Bilim Dali:	Bilgisayar Muhendisligi
Teslim Tarihi:	April 2026

Not: Kose parantezli alanlar universite, ogrenci ve danisman bilgilerine gore doldurulmak uzere birakilmistir. Bu surum akademik proposal biciminde, atifli ve kaynakcali olarak hazirlanmistir.

İçindekiler

Ozet	ii
1 Giriş	1
2 Problem Tanımı	1
3 Arastırma Soruları ve Hipotezler	1
3.1 Arastırma Soruları	1
3.2 Hipotezler	2
4 Arastırmanın Önemi ve Katkısı	2
5 Literatur Taraması	2
5.1 Adaptive Time Quantum Scheduling	2
5.2 AI Tabanlı Scheduler Yaklaşımları	3
5.3 Hardware Aging ve Reliability-Aware Control	3
5.4 Literatur Bölümü	3
6 Önerilen Yöntem	3
6.1 Genel Çerçeve	3
6.2 Yöntem 1: Heuristic Aging-Penalized Quantum	4
6.3 Yöntem 2: Physics-Informed Supervised Learning	4
6.4 Yöntem 3: Contextual Bandit ve Reinforcement Learning	4
7 Deneysel Tasarım	5
7.1 Simulator Ortamı	5
7.2 Workload Sınıfları	5
7.3 Baseline Yöntemler	5
7.4 Thermal ve Aging Modelleri	6
8 Değerlendirme Metrikleri	6
8.1 Scheduler Performansı	6
8.2 Reliability ve Thermal Metrikleri	6
8.3 Temel Karşılaştırma İddiaları	6
9 Örnek Senaryo ve Objektif Beklenti Çerçevesi	7
9.1 Örnek Senaryo	7
9.2 Muhtemel Pozitif Sonuçlar	7
9.3 Muhtemel Negatif Sonuçlar ve Sınırlar	8
9.4 Objektif Başarı Kriterleri	8
10 Beklenen Zorluklar ve Risk Azaltma	8
11 Çalışma Planı	8
12 Beklenen Sonuçlar	9
13 Sonuç	10

Ozet

Bu arastirma onerisi, klasik CPU scheduling literaturundeki *adaptive time quantum secimi* ile hardware reliability literaturundeki *aging-aware runtime control* yaklasimlarini tek bir kontrol cercevesinde birlestirmeyi amaclamaktadir. Mevcut Round Robin turevi scheduler calismalari, quantum degerini burst time, ready-queue uzunlugu veya istatistiksel ozetler uzerinden belirlemeye odaklanirken; reliability-aware sistemler termal yonetim, DVFS, task remapping ve online monitor geri bildirimi kullanarak donanim omrunu korumaya calismaktadir [1, 3, 6, 9]. Ancak scheduler seviyesinde quantum seciminin dogrudan thermal ve aging telemetry ile birlestirildigi arastirma sayisi halen sinirlidir.

Bu calismada, queue-state, thermal durum ve aging estimate bilgisini ayni kontrol dongusunda kullanan bir *aging-aware adaptive scheduler* tasarlanmasi onerilmektedir. Onerilen yontemsel cerceve uc asamalidir: (i) heuristic aging-penalty tabanli quantum secimi, (ii) physics-informed supervised learning ile optimum quantum prediction, (iii) kontekstual bandit veya reinforcement learning tabanli policy ogrenimi. Arastirmanin temel hipotezi, boyle bir scheduler'in ya ayni performans seviyesinde daha dusuk aging birikimi ya da ayni aging butcesi altinda daha iyi performans saglayabilecegidir.

Anahtar Kelimeler: adaptive scheduling, Round Robin, time quantum, hardware aging, reliability-aware control, reinforcement learning

3. Physics-informed supervised learning veya RL tabanlı policy'ler, heuristic yöntemlere göre workload dağılımı altında daha iyi genelleme yapabilir mi?
4. Scheduler karar uzayına migration ve DVFS eklendiğinde projected lifetime üzerinde anlamlı iyileşme elde edilir mi?

3.2. Hipotezler

1. Queue-aware ve aging-aware hibrit scheduler'lar, geleneksel dynamic RR scheduler'lara göre daha iyi bir latency-reliability dengesi sağlar.
2. Thermal ve aging state quantum seçimine dahil edildiğinde hotspot davranışı ve birikimli stres dağılımı azalır.
3. Physics-informed supervised modeller, saf istatistik tabanlı scheduler'lardan daha iyi quantum seçimi yapabilir.
4. RL tabanlı denetim, uygun reward ve güvenlik kısıtları ile uzun vadeli aging maliyetini azaltabilir.

4. Arastırmanın Önemi ve Katkısı

Bu araştırmanın önemi dört noktada toplanabilir:

1. Scheduling literatürü ile aging-aware reliability literatürünü birleştirmesi
2. Quantum seçimini sadece performans değil, aynı zamanda donanım sağlığı problemi olarak ele alması
3. Heuristic, supervised learning ve RL tabanlı yöntemleri ortak bir simulator altında karşılaştırması
4. “same performance, less aging” ve “same aging budget, better performance” iddialarını nicel olarak test etmesi

5. Literatur Taraması

5.1. Adaptive Time Quantum Scheduling

Round Robin scheduler üzerinde quantum seçiminin dinamikleştirilmesi uzun süredir çalışılan bir alandır. Behera ve ark. yeniden ayarlanmış dynamic quantum yöntemi ile context switch ve turnaround time açısından iyileşme raporlamıştır [1]. Noon ve ark. ise quantum değerini mean burst time tabanlı bir kural ile seçmiştir [2]. Daha yakın tarihli çalışmalarda median-average ve percentile tabanlı daha dayanıklı yaklaşımlar önerilmiştir [3, 4]. Bu literatür, workload-aware

quantum seciminin faydalı olduğunu gösterse de, termal ve aging etkileri çoğu zaman modelin dışında bırakılmıştır.

5.2. AI Tabanlı Scheduler Yaklaşımları

AI tabanlı scheduler çalışmaları artmakla birlikte, quantum secimini doğrudan bir sequential decision problemi olarak ele alan çalışma sayısı azdır. Chitaliya ve ark. quantum optimizasyonunu bir tahmin problemi olarak formüle edip ML modelleri ile optimum quantum kestirimi denemistir [5]. Buna karşılık scheduler-level RL çalışmaları geniş ama dağınık bir literatür oluşturmakta; gerçek CPU quantum secimi ile doğrudan bağ kuran çalışma sayısı sınırlıdır.

5.3. Hardware Aging ve Reliability-Aware Control

Srinivasan ve ark. lifetime reliability-aware microprocessors fikrini ortaya koyarak mikroislemci tasarımı aging'i temel bir sistem seviyesi sorun olarak tanımlamıştır [6]. Agarwal ve ark. transistor aging için failure prediction mekanizmalarını one çıkarırken [7], Kumar ve ark. aging kaynaklı performans bozulmasını telafi etmek için adaptif devre seviyesinde teknikler geliştirmiştir [9]. Reliability-aware DVFS ve runtime thermal management çalışmaları da performans ile lifetime arasındaki trade-off'un scheduler ve runtime katmanında yönetilebileceğini göstermektedir [8, 10].

5.4. Literatür Bosluğu

Literatürdeki ana boşluklar şu şekildedir:

- Quantum secimi çalışmaları hardware aging bilgisini kullanmaz.
- Aging-aware control çalışmaları scheduler quantum'unu doğrudan karar degişkeni olarak kullanmaz.
- AI tabanlı scheduler yaklaşımları reliability-centric objective kurmakta zayıftır.

Bu proposal tam olarak bu boşta konumlanmaktadır.

6. Önerilen Yöntem

6.1. Genel Çerçeve

Önerilen sistem dört temel bileşenden oluşur:

1. Workload generator veya trace source
2. Scheduler engine
3. Thermal estimator ve aging estimator

4. Logging, evaluation ve analysis katmani

Policy katmani queue-state, thermal telemetry ve aging estimate bilgisini alarak quantum, migration ve opsiyonel olarak DVFS karari uretecektir.

6.2. Yontem 1: Heuristic Aging-Penalized Quantum

Ilk yontem aciklanabilir bir baseline olarak tanimlanmaktadir:

$$Q_t = f(S_t^{queue}) - \lambda_1 g(S_t^{thermal}) - \lambda_2 h(S_t^{aging})$$

Burada f , mean/median/quartile tabanlı temel quantum uretir; g ve h ise sicaklik, hotspot severity, thermal gradient, cumulative stress ve tahmini slack loss gibi sinyallere dayali ceza fonksiyonlaridir.

6.3. Yontem 2: Physics-Informed Supervised Learning

Bu asamada optimum quantum secimi bir prediction problemi olarak ele alinacaktir. Farkli workload pencereleri icin farkli quantum degerleri taranarak bir objective tanimlanacaktir:

$$J = w_1 \cdot \text{Latency} + w_2 \cdot \text{ContextSwitchCost} + w_3 \cdot \text{ThermalCost} + w_4 \cdot \text{AgingCost}$$

Minimum J veren quantum “etiket” olarak atanacak ve Random Forest, XGBoost, LightGBM gibi modellerle quantum prediction yapılacaktır. Bu yontem physics-informed olarak adlandirilir; cunku etiketleme ve feature tasarimi thermal ve aging anlami tasiyan degiskenler uzerinden kurulacaktır.

6.4. Yontem 3: Contextual Bandit ve Reinforcement Learning

Daha ileri asamada scheduler sequential decision problemi olarak ele alinacaktir. State uzayi queue length, remaining burst statistics, per-core utilization, current temperature, temperature gradient, cumulative aging score, onceki quantum ve migration history gibi ozellikleri icerecektir. Reward genel olarak asagidaki bicimde tasarlanabilir:

$$R_t = \alpha \cdot \text{Throughput}_t - \beta \cdot \text{ResponseTime}_t - \gamma \cdot \text{ContextSwitches}_t - \delta \cdot \text{HotspotPenalty}_t - \eta \cdot \text{AgingIncrement}_t$$

Bu asamada DQN, Double DQN veya PPO gibi algoritmalar denenebilir. Ancak tum AI policy’leri bir safety filter altinda calisacak; peak temperature limiti, starvation prevention ve max migration rate gibi kurallar korunacaktır.

7. Deneysel Tasarım

7.1. Simulator Ortami

İlk asamada Python tabanlı discrete-event scheduler simulator kurulması planlanmaktadır. Bu seçim, hızlı deneysellik, tekrarlanabilirlik ve policy varyantlarını kolay karşılaştırma avantajları sağlamaktadır. İleri asamada gem5 veya Sniper entegrasyonu opsiyonel olarak düşünülebilir.

7.2. Workload Siniflari

Tablo 1: Planlanan workload siniflari.

Sinif	Tur	Aciklama
Kisa CPU-bound	Sentetik	Kisa burst'ler; response time hassasiyeti yuksek
Uzun CPU-bound	Sentetik	Uzun burst'ler; quantum buyuklugune hassas
Heavy-tail bursts	Sentetik	Pareto benzeri uzun-kuyruk dagilim
Bursty arrivals	Sentetik	Kume halinde gelen prosesler ile queue baskisi
Periodic tasks	Sentetik	Gercek-zaman benzeri duzenli isler
Hot-core stress	Senaryo	Ayni cekirdekte aging birikimini zorlayan dagilim
Balanced multicore mix	Senaryo	Wear-leveling davranisini olcmeye uygun karisik yuk
Trace-driven mix	Gercekci	Mumkunse gercek scheduler trace'lerinden tu-retilmis isler

7.3. Baseline Yontemler

1. Fixed Round Robin
2. Mean-based dynamic RR
3. Median/quartile-based dynamic RR
4. Thermal-aware scheduler
5. Aging-aware fakat AI icermeyen scheduler
6. Onerilen heuristic hybrid scheduler
7. Onerilen supervised scheduler
8. Onerilen bandit / RL scheduler

7.4. Thermal ve Aging Modelleri

Termal model asagidaki sekilde basit ama tutarli bir formda ele alinacaktır:

$$T_{t+1} = aT_t + bU_t + cS_t + dT_{amb}$$

Burada U_t utilization, S_t switching proxy ve T_{amb} ortam sicakligidir. Aging increment ise:

$$\Delta A_t = k_1 e^{\rho T_t} + k_2 U_t^p + k_3 C_t$$

Burada C_t , context-switch veya switching-rate kaynakli ek stresi temsil eder. Ileri asamada BTI-like, HCI-like, EM proxy ve thermal-cycling bilesenleri ayri takip edilebilir.

8. Degerlendirme Metrikleri

8.1. Scheduler Performansi

- Average waiting time
- Average turnaround time
- Average response time
- Throughput
- Context switch count
- Fairness ve starvation gostergeleri

8.2. Reliability ve Thermal Metrikleri

- Peak temperature
- Mean temperature per core
- Thermal gradient
- Thermal cycling severity
- Cumulative aging score
- Projected lifetime proxy

8.3. Temel Karsilastirma Iddialari

Bu proposal su iki iddiayi test edecektir:

- Aynı performans seviyesinde daha düşük aging birikimi
- Aynı aging butcesi altında daha iyi performans

9. Örnek Senaryo ve Objektif Beklenti Çerçevesi

Bu bölüm, önerilen sistemin nasıl davranacağını somut bir senaryo altında göstermek ve aynı zamanda çalışmadan beklenen fayda ile olası sınırları açık biçimde ifade etmek için eklenmiştir.

9.1. Örnek Senaryo

Dört çekirdekli bir sistem düşünülün. Ready queue içinde hem kısa hem uzun CPU-bound işler bulunmaktadır. Sistem belirli bir zaman penceresinde şu koşullara girsin:

- Core 1 uzun süredir yüksek utilization altında çalışmaktadır.
- Core 1 sıcaklığı diğer çekirdeklerden daha yüksektir.
- Core 1 için aging score diğer çekirdeklere göre daha hızlı artmaktadır.
- Queue doluluk oranı yüksektir; dolayısıyla scheduler performans baskısı altındadır.

Bu durumda geleneksel bir dynamic RR scheduler büyük olasılıkla queue basıncını azaltmak için quantum'u arttıracak, fakat bunu yaparken donanım sağlığı bilgisini kullanmadığı için aynı çekirdeğin üzerindeki stresi daha da arttırabilecektir. Önerilen aging-aware scheduler ise aynı anda şu aksiyonlardan birini veya birkaçını birlikte değerlendirecektir:

1. quantum değerini queue baskısına göre arttırmak, fakat thermal/aging cezası nedeniyle bu artış miktarını sınırlamak
2. işi daha az yorulmuş bir çekirdeğe migrate etmek
3. gerekiyorsa ilgili çekirdekte DVFS ile frekans/voltaj seviyesini daha korumacı moda almak
4. fairness bozuluyorsa migration veya quantum kararını filtrelemek

Bu senaryo, sistemin sadece “hangi iş ne kadar süre çalışsın” değil, aynı zamanda “bu karar donanımı nasıl etkileyecek” sorusuna cevap veren bir scheduler olduğunu gösterir.

9.2. Muhtemel Pozitif Sonuçlar

Bu senaryo altında beklenebilecek olumlu sonuçlar şunlardır:

- belirli çekirdeklerde hotspot davranışının azalması
- core bazlı aging score dağılımının daha dengeli hale gelmesi
- sabit RR veya yalnızca queue-statistics tabanlı RR'a göre benzer throughput altında daha düşük aging birikimi

- thermal gradient ve peak temperature degerlerinde azalma
- uzun sureli kosullarda projected lifetime proxy'sinde iyilesme

9.3. Muhtemel Negatif Sonuclar ve Sinirlar

Bu proposal'in objektif degerlendirilmesi icin, olumsuz veya sinirli sonuc ihtimalleri de acik bicimde kabul edilmelidir:

- migration ve policy hesaplama overhead'i nedeniyle toplam latency bazen artabilir
- aging korumasi fazla agresif olursa throughput veya turnaround time kotulesebilir
- thermal bilgi aging'i tek basina temsil etmeyebilir; bu nedenle proxy modeli eksik kalabilir
- RL tabanlı policy, egitim verisine veya reward agirliklarina hassas olabilir
- simulator sonucunda gozlenen fayda, gercek sistem entegrasyonunda daha kucuk kalabilir
- bazi workload ailelerinde klasik dynamic RR zaten yeterince iyi calisiyorsa ek kazanc sinirli olabilir

9.4. Objektif Basari Kriterleri

Calisma ancak asagidaki turden bir sonuc gosterebilirse guclu kabul edilmelidir:

1. ayni throughput altinda istatistiksel olarak anlamlı aging score azalması
2. ayni aging butcesi altinda waiting time veya turnaround time iyilesmesi
3. peak temperature ve hotspot sayisinda acik azalma
4. birden fazla workload sinifinda tutarli iyilesme

Eger bu kriterler saglanmazsa, proposal'in degerli ciktisi yine de su olabilir: scheduler-level aging-aware kontrolun hangi kosullarda faydali oldugu ve hangi kosullarda overhead nedeniyle zayif kaldiginin acikca ortaya konmasi.

10. Beklenen Zorluklar ve Risk Azaltma

11. Calisma Plani

Risk	Sorun	Azaltma Stratejisi
Aging model sade kalmasi	Fiziksel gercekligi eksik temsil etme	Sensitivity analysis, alternatif proxy'ler ve parametre taramasi
Sentetik workload bias	Gercek sistem davranisinin eksik yansimasi	Trace-driven workload ve farkli dagilim aileleri kullanma
RL kararsizligi	Reward hassasiyeti ve egitim zorlugu	Once heuristic ve supervised baseline'lari oturtma
Policy overhead	Kontrol maliyetinin kazanci silmesi	Ayrik action space ve seyrek update
Fairness bozulmasi	Aging koruması bazı işleri cezalandırabilir	Fairness cezası ve starvation bounds

Literatur ve proposal sonlandirma	
Baseline simulator	
Thermal ve aging model entegrasyonu	
Heuristic hybrid scheduler	
Veri uretimi ve etiketleme	
Supervised model deneyleri	
Bandit / RL deneyleri	
Ablation, analiz ve final yazim	

12. Beklenen Sonuclar

Beklenen sonuc, önerilen scheduler'ın geleneksel scheduler'lara göre daha iyi bir performance-reliability trade-off'u göstermesidir. En güçlü deneysel sonuç tipleri şunlar olacaktır:

1. Benzer throughput altinda anlamlı aging score azalması
2. Benzer aging limiti altinda daha düşük waiting/turnaround time
3. Peak temperature ve hotspot davranisinda iyileşme
4. Workload aileleri boyunca daha tutarlı scheduler davranisi

Ancak objektif bir degerlendirme icin su ihtimaller de raporlanmalidir:

- bazı workload'larda kazanç çok küçük olabilir

- bazı policy'ler aging'i azaltırken latency'yi arttırabilir
- en iyi performansi veren policy ile en iyi reliability sonucu veren policy ayni olmayabilir
- RL tabanlı surum, heuristic veya supervised surumden her zaman daha iyi cikmayabilir

Dolayisiyla calismanin amaci yalnızca “onerilen yontem her kosulda en iyidir” demek degil; hangi kosullarda avantaj sagladigini, hangi kosullarda maliyet olusturdugunu ve trade-off yuzeyinin nasıl sekillendigini gostermeştir.

13. Sonuc

Bu proposal, adaptive time quantum scheduling ile aging-aware runtime control arasındaki boşluğu doldurmaya yönelik ayrıntılı ve uygulanabilir bir araştırma çerçevesi sunmaktadır. Onerilen sistem, quantum seçimini yalnızca performans problemine indirgememekte; aynı zamanda donanım sağlığını da karar mekanizmasına dahil etmektedir. Bu yönüyle çalışma, işletim sistemleri, bilgisayar mimarisi ve AI for systems alanlarının kesisiminde anlamlı bir katkı potansiyeli taşımaktadır.

Kaynaklar

- [1] H. S. Behera, R. K. Mohanty, and D. Nayak, “A New Proposed Dynamic Quantum with Re-Adjusted Round Robin Scheduling Algorithm and Its Performance Analysis,” *International Journal of Computer Applications*, 2010.
- [2] A. Noon, A. Kalakech, and S. Kadry, “A New Round Robin Based Scheduling Algorithm for Operating Systems: Dynamic Quantum Using the Mean Average,” arXiv preprint arXiv:1111.5348, 2011.
- [3] Sakshi, C. Sharma, S. Sharma, S. Kautish, S. A. M. Alsallami, E. M. Khalil, and A. W. Mohamed, “A New Median-Average Round Robin Scheduling Algorithm,” *Alexandria Engineering Journal*, 2022.
- [4] M. F. Zohora, F. Farhin, and M. S. Kaiser, “An Enhanced Round Robin Using Dynamic Time Quantum for Real-Time Asymmetric Burst Length Processes,” *PLOS ONE*, 2024.
- [5] P. Chitaliya et al., “Time Quantum Optimization in Round Robin Algorithm,” *NMITCON*, 2023.
- [6] J. Srinivasan et al., “The Case for Lifetime Reliability-Aware Microprocessors,” *ISCA*, 2004.
- [7] M. Agarwal et al., “Circuit Failure Prediction and Its Application to Transistor Aging,” *VTS*, 2007.
- [8] H. Aydin and D. Zhu, “Reliability-Aware Energy Management for Periodic Real-Time Tasks,” *IEEE Transactions on Computers*, 2009.
- [9] S. V. Kumar, C. H. Kim, and S. S. Sapatnekar, “Adaptive Techniques for Overcoming Performance Degradation Due to Aging in CMOS Circuits,” *IEEE Transactions on VLSI Systems*, 2011.
- [10] A. Yeganeh-Khaksar et al., “Ring-DVFS: Reliability-Aware Reinforcement Learning-Based DVFS for Real-Time Embedded Systems,” *IEEE Embedded Systems Letters*, 2021.